Prueba técnica - Data & Desarrollo MOVE

Sobre la prueba

Podés usar las herramientas que usas normalmente, incluida la IA. Lo único que pedimos es que lo cuentes. Usar IA no resta; lo que sí importa es que entiendas y puedas explicar lo que entregás.

Qué entregar

Un solo Jupyter notebook (.ipynb) en Python 3, con una sección por ejercicio.

- **Que corra de punta a punta:** Indicá al principio qué librerías usaste y dónde van los archivos de datos.
- **Que se lea tu razonamiento:** Usá celdas de markdown para anotar qué vas a hacer, por qué y qué encontraste. No hace falta que sea largo: unas líneas por paso alcanzan.
- **Las queries de SQL dentro del notebook:** ejecutadas contra la base, con el texto de cada consulta visible.
- **Una sección final "Uso de IA":** qué herramientas usaste, para qué, y algún momento en que te dió algo que estaba mal o tuviste que corregir. Si no usaste, aclaralo también.

Ejercicio 1: modelo de predicción electoral

Situación del ejercicio: Es octubre del 2020 y un cliente quiere anticipar en qué condados de Estados Unidos va a ganar cada partido en la elección presidencial, usando datos sociodemográficos. Tu tarea es armar ese modelo y decirle qué tan confiable es.

Descargá el dataset US Census and Election Results (2000–2020) de Kaggle el cual trae dos archivos:

- **county_census_and_election_result.csv:** una fila por condado y año, con variables del censo (ingreso, edad, educación, composición étnica, empleo, etc.) y resultados presidenciales.
- **meta_data.csv:** qué significa cada columna.

La variable a predecir es winner: 1 si ganó el partido republicano, 0 si ganó el demócrata.

Qué tiene que tener tu notebook:

1. **EDA:** Qué representa cada fila, qué años hay, qué falta, qué te llamó la atención, etc.
2. **Preparación:** Qué filas y qué variables usás, y por qué. Si descartás algo, explicá el motivo.
3. **Modelado:** Entrená solo con elecciones anteriores a 2020. Probá al menos dos modelos de ML y contá cuáles elegiste y por qué. Incluí también una regla simple sin ML (una “línea de base”) contra la cual comparar, por ejemplo, predecir siempre el resultado más frecuente. Al final, decí cuál le recomendarías al cliente.
4. **Evaluación:** Con las métricas que te parezcan adecuadas, explicando por qué las elegiste.
5. **Conclusiones para el cliente:** Qué variables pesan más y cómo lo interpretás, y qué limitaciones le advertirías antes de que use el modelo.

Ejercicio 2: SQL sobre una base de encuestas

Te adjuntamos encuestas.sql, una base de PostgreSQL con tres olas mensuales de un tracking de opinión pública.

Cómo cargarla: Cualquier Postgres 13 o superior sirve. Si no tenés uno instalado, la forma más rápida es con Docker:

```
docker run --name prueba-pg -e POSTGRES_PASSWORD=prueba -p 5432:5432 -d postgres:16
# esperá unos segundos a que levante y cargá la base:
docker exec -i prueba-pg psql -U postgres < encuestas.sql
```

También podés usar un Postgres gratuito en la nube, como Supabase o Neon.

Tablas

Tabla	Qué tiene
encuestas	Una fila por ola: nombre, fechas y modalidad (IVR u Online).
encuestados	Una fila por persona y ola: sexo, edad, provincia, si completó el cuestionario y su `ponderador`.
provincias	Las 24 provincias con su región.
preguntas	Las preguntas de cada ola. Cada ola tiene sus propios `id`, pero el `codigo` es el mismo (`APROB`, `VOTO`).
opciones	Las etiquetas de cada valor de respuesta. El 99 es siempre Ns/Nc.
respuestas	Una fila por respuesta registrada, con fecha y hora.

Reglas de negocio a tener en cuenta

- Los análisis se hacen solo con encuestas completas.
- Si una persona tiene más de una respuesta registrada para la misma pregunta, vale la última registrada.

CONSULTAS SQL

1. Para cada ola, la cantidad de encuestados con encuesta completa y su edad promedio.
2. En la última ola, el porcentaje de aprobación, desaprobación y Ns/Nc (No sabe o no contesta) de la gestión por región (sin ponderar).
3. La intención de voto ponderada de cada ola: el porcentaje de cada opción, incluyendo Ns/Nc y En blanco, usando el ponderador.
4. A partir de la anterior, para cada espacio político (sin contar Ns/Nc ni En blanco): la variación en puntos respecto de la ola anterior y su posición en el ranking de cada ola.

Si encontrás problemas en los datos, contanos cuáles y cómo los resolviste.

Qué valoramos

Más que llegar al mejor número, nos interesa cómo pensás: que mires los datos antes de modelar, que las decisiones estén justificadas y que seas honesto con lo que no salió o no llegaste a hacer. Un trabajo prolijo e incompleto vale más que uno completo que no se entiende.

Si algo de la consigna no está claro, escribinos. Y si tenés que asumir algo para avanzar, anotalo en el notebook y seguí. Éxitos!